


Safe Guard — 대화 분석·문서 생성 작동 방식

담당 기능 #2(수집한 대화의 AI 분석) · #4(분석 결과의 문서 정리) / NestJS 백엔드
마지막 갱신 2026-09-08 · 실측 수치는 메시지 단위 시절(2026-08)의 값이며, 구간 단위 전환 후 실시 재측정은 대기 중이다(6절).

1. 한눈에 보기

대화 내보내기 파일 하나가 정리 문서 PDF가 되기까지:



- AI 호출은 ②와 ④, 딱 두 번. 나머지는 전부 결정론적 코드다.
- 판단 단위는 "구간" — 같은 행위를 이루는 메시지 묶음(예: 심부름 요구 → 거절 무시 → 불이익 암시 → 요구 가중 = 구간 1개). 단독 발화도 구간 1개다. 법적 판단 단위가 개별 문장이 아니라 행위이기 때문이고, 공갈처럼 요건이 여러 메시지에 나뉘는 사안의 판례 매칭이 좋아진다.
- 원칙: 의미 판단은 AI가, 숫자 집계·법조항은 코드가. AI에게 법조를 맡기면 없는 조항을 지어내고(할루시네이션), 개별 사안에 법을 적용해 판단해 주는 것은 법률사무여서 변호사법 문제가 생긴다. 조문·형량은 국가법령정보 API에서 수집한 원문만 쓴다.
- 이 분석은 참고용이며 법적 판단이 아니다. 문서 매 페이지에 면책이 박힌다.

실측 (57건 학급 단독 샘플 기준):

구간	값
1차 선별	약 24초, 후보 30건
2차 판단	약 48초, 확정 29건 (탈락 1건)
토근	입력 약 14,000 / 출력 약 5,000
정리 문서	A4 7페이지, 400~500KB

2. 코드 지도

src/safeguard/	
└─ kakao-parser.ts	① 카톡 내보내기 파서 (3형식 자동 감지)
└─ anonymizer.ts	① 가명화 - 실명·연락처는 기기 밖으로 안 나감
└─ safeguard-analysis.service.ts	②④⑥ 1차·2차 프롬프트, 코드 패턴 검출, 집계
└─ precedent-provider.ts	③ 판례 모듈 계약(입출력 바디) + 목업
└─ law-registry.ts	⑦ 유형→조문 매핑, 형량 추출, DM 분기
└─ law-api.service.ts	법령 API 동기화 (런타임 호출 안 함)
└─ report-pdf.service.ts	⑧ Puppeteer PDF
└─ safeguard.controller.ts	HTTP 계층 (분석 스트리밍 · PDF)
└─ dto/analyze.dto.ts	요청 검증 (class-validator)
└─ safeguard.module.ts	
data/law-articles.json	조문 16건 - 법령 API 원문 스냅샷
data/판례-풀.json	판례 14건 - 사건번호·판시사항 전부 판례 API 원문
public/safeguard-ui.html	모바일 UI

3. HTTP API

GET / — UI

모바일 전용 화면. 업로드 → 확인(대화방 종류·피해자 선택) → 분석 진행 → 결과·다운로드.

POST /api/analyze — 분석

```
// 요청
{ "rawText": "<내보내기 파일 원문>",
  "context": "dm | small_group | large_group | public",
  "victimName": "윤아" }
```

응답은 `application/x-ndjson` 스트림 — 파이프라인이 도는 동안 진행 이벤트가 한 줄씩 온다:

```
{ "type": "stage", "stage": "anonymize" }
{ "type": "stage", "stage": "screen" }
{ "type": "stage", "stage": "screen_done", "candidates": 30 }
{ "type": "stage", "stage": "match_done", "precedents": 13 }
{ "type": "stage", "stage": "judge" }
{ "type": "stage", "stage": "judge_done", "flagged": 29 }
{ "type": "result", "flagged": [ ... ], "patterns": [ "떼카", "카톡감옥", "서툴" ] }
// 실패 시: { "type": "error", "message": "..." }
```

`flagged` 항목 형태 — 항목 1개 = 구간 1개:

```
{ "messageNos": [32, 34, 35, 40], // 구간에 속한 가해 발화 번호들 - 원문은 클라이언트가 자기 파싱본에서 조회
  "harmTypes": ["협박", "갈취강요"], // 8종 중 복수 가능 (구간 전체 행위에 대한 판정)
  "severity": "즉시조치", // 관찰 | 주의 | 즉시조치 (점수 아님)
  "reason": "...해악 고지", // 판단 근거 한 줄
  "appliedPrecedentIds": ["2003도709"] } // 실제 근거로 쓴 판례 (내부 추적용, 문서엔 안 나감)
```

진행 이벤트의 `screen_done` 은 `candidates` (구간 수)와 `messages` (구간에 포함된 메시지 수)를 함께 준다.

POST /api/report — 정리 문서 PDF

```
// 요청 = analyze 요청 + 그 결과
{ "rawText": "...", "context": "...", "victimName": "...",
  "result": { "flagged": [...], "patterns": [...] },
  "legal": true } // true: 조항·절차 포함 / false: 판단 근거만
```

응답: application/pdf.

- `context` 는 enum으로 강제 검증한다(ValidationPipe). 이 값 하나로 적용 법조가 통째로 걸리기 때문(6절)에 잘못 들어오면 400으로 거절한다.
- `whitelist: true` 라서 검증 데코레이터가 없는 DTO 필드는 조용히 제거된다. 필드를 추가할 땐 반드시 데코레이터를 붙일 것 (실제로 `no` 필드가 스트립되어 PDF 생성이 터진 적이 있다).

4. 단계별 상세

① 파싱 — `kakao-parser.ts`

카카오톡 내보내기 두 형식을 자동 감지한다:

PC형:	[민준] [오후 2:20] 본문	← 날짜는 구분선에서 상태로 유지
모바일형:	2026. 6. 23. 오후 10:59, 이름 : 본문	← 매 줄에 날짜
	2026. 6. 23. 오후 10:59: A님이 B님과 C님을 초대했습니다.	← 시스템 줄은 침표가 아니라 콜론
	메시지가 삭제되었습니다.	← 시각 없는 단독 줄

처리하는 것: 오전·오후→24시간(오후 12시는 12시, 오전 12시는 00시), 여러 줄 메시지 병합, 시스템 이벤트(나감·초대·강퇴·삭제) 추출, 다중 초대의 대상 분해 ("A님, B님과 C님을 초대" → `targets: [A,B,C]`).

시스템 이벤트가 중요한 이유: 카톡감옥·방폭은 텍스트에 욕설이 0건이라 입·퇴장 로그가 유일한 증거다.

① 가명화 — `anonymizer.ts`

외부(AI API·판례 검색)로 나가기 전에 신원을 지운다:

민준→학생A · 윤아→학생E ... "야 김윤아" → "야 학생E" (성이 붙은 형태까지 흡수)
전화번호 → [전화번호] · 주민번호 → [주민번호] · URL → [링크]

- 가명↔실명 매핑은 서버 메모리에만 존재한다. AI가 돌려준 `reason` 은 역치환한다.
- 메시지 번호(`no`) 는 순서 기반이라 가명화와 무관하게 앵커로 동작한다.
- 한계: 참여자 목록에 없는 제3자 실명은 잡지 못한다. 완전한 익명화가 아니라 최선 노력(best-effort) 마스킹이다.

같은 시점에 코드 패턴 검출이 돈다 — AI 없이 결정론적으로:

카톡감옥: 피해자 퇴장 → 재초대 2회 이상
방폭: 피해자 초대·입장 후 10분 내 타인 2명 이상 퇴장

의미 판단이 필요한 나머지 패턴(떼카·서틀·은따·저격글·반톡배제)은 1차 AI가 관찰하고, 최종 `patterns` 는 둘의 합집합이다. AI가 놓쳐도 코드가 잡는 안전망.

② 1차 선별 — AI, effort low

번호 매긴 대화 전문을 주고 "유해 후보를 골라 같은 행위끼리 구간으로 묶어라"를 시킨다. 1차는 전체 대화를 읽는 유일한 AI 단계다.

- **애매하면 포함** — 여기서 빠진 메시지는 이후 단계에 전달되지 않는다(미탐은 복구 불가). 잘못 들어간 것은 2차가 거른다.
- 확실히 무해한 것만 제외: 일상 대화, 피해자 발화, 무례·불쾌 수준, 지목 없는 감탄사형 욕설("ㅅㅂ 시험 망함"), 일상 초성체(ㅇㅋ, ㄱㅅ, ㄴㅇㄴ...), 쌍방 장난.
- 동조성 반응은 포함: 비하 직후의 "ㅋㅋㅋㅋ"."ㅇㅈ"."ㄱㄱ"는 집단따돌림의 구성 발화다(가해자만 웃고 대상자는 웃지 않으면 조롱).
- 구간 묶기 규칙: 구간 하나 = 행위 하나 (머칠에 걸쳐도 같은 요구의 반복이면 한 구간), 다른 행위는 다른 구간, `messageNos` 에는 가해 측 발화만(피해자 발화는 흐름 판단에만 사용), 동조성 반응은 따라붙은 발화와 같은 구간, 한 메시지는 한 구간에만.
- 구간마다 세 가지를 붙인다: - `messageNos` — 구간에 속한 가해 발화 번호 (오름차순) - `victimIdentifiable` — 특정성. 이름·2인칭·멘션뿐 아니라 "어떤 애가" 식 맥락 지목 포함 - `summary` — 누가 무엇을 어떤 순서로 했는지 사실만 한두 문장. 2차의 참고이자 **벡터 검색** 질의로도 쓰인다. **죄명·유형 단어 금지** (1차의 판정이 섞이면 2차가 그것에 끌려가는 앵커링이 실측에서 확인되어 금지 규칙을 넣었다)
- 코드가 AI 출력의 번호를 정리한다 — 범위 밖·중복 제거, 오름차순, 빈 구간 제거.

③ 판례 매칭 — 팀원 모듈 (현재 목표)

계약(입출력 바디)은 `precedent-provider.ts` 에 타입으로 고정돼 있다:

```
입력: analysisTargets[] = { targetMessageId, targetText,
                           legalContext: { isGroupChat, audienceCount, victimIdentifiable } }
출력: precedentDict      = { 사건번호: 요지 한 줄 }           ← 중복 제거된 사전
      analysisTargets[] + matchedPrecedentIds[3]             ← 구간엔 번호만
```

타깃 1개 = 구간 1개. 계약 형태는 메시지 단위 때와 동일하고 의미만 바뀌었다 —

`targetMessageId` 는 구간의 메시지 번호 나열("32,34,35,40"), `targetText` 는 1차의 사실 요약 + 구간 원문을 이어 붙인 문자열이다. 요약은 구어 원문보다 판시사항 문체에 가까워 검색 질의로 유리하고, 원문은 검색 근거의 손실을 막는다. 벡터 모듈 쪽은 "텍스트가 여러 문장일 수 있다"는 것만 알면 되고 코드 수정은 필요 없다.

- `isGroupChat` · `audienceCount` 는 코드가(방 정보), `victimIdentifiable` 은 1차 AI가 채운다.
- 실제 구현은 팀원의 벡터 DB — `targetText`와 가장 가까운 판례 문구 3개를 자연어 검색으로 리턴. 준비 전까지 `MockPrecedentProvider` (문자 바이그램 코사인)가 같은 계약으로 동작한다. 교체 지점은 `safeguard-analysis.service.ts` 의 `precedents` 필드 하나.
- top-3는 임계값이 없어서 무관한 판례도 반드시 3개가 붙는다 — 그래서 2차 프롬프트에 "무관하면 버려라"가 있다.

데이터: `data/판례-풀.json` 14건. **사건번호·요지 전부 판례 API 원문**이다 (지어낸 요지가 DB에 들어가면 2차 판단 전체가 오염된다). 집단따돌림은 판례 DB에 실체 판시가 없어 학폭법 2조 정의 조문이 판단 근거임을 풀에 명시했다.

④ 2차 판단 — AI, effort medium

대화 전문 없이 **판례 사전 + 후보 구간 목록**을 받는다. 구간마다 첫 발화 앞 1줄부터 마지막 발화 뒤 1줄까지의 원문이 통째로 들어간다:

[구간 0032,0034,0035,0040] 피해자 식별: 예 · 판례 후보: 2003도709, ...

[0031] 학생A: 야 학생E

▶ [0032] 학생A: 내일 매점에서 빵 사와라

← ▶ = 구간 소속 발화

[0033] 학생E: 나 돈 없는데

← 표시 없음 = 사이의 피해자 응답 (맥락)

▶ [0034] 학생A: 없으면 만들어와야지

▶ [0035] 학생A: 안사오면 어떻게 되는지 알지

...

▶ [0040] 학생A: 그럼 내일은 두 개 사와

[0041] 학생E: 알겠어

요약: 심부름을 요구하고 거절을 무시한 뒤 불이익을 암시, 이튿날 요구를 늘림 ← 1차 요약 (참고용)

2차는 구간 단위로 유형·정도를 판정하고, 한 구간이 실제로 별개 행위 둘이면 messageNos 를 나눠 두 항목으로 낼 수 있다 (합치기는 금지). 유해하지 않은 발화 번호는 빼고 반환한다.

핵심 규칙:

- 판례는 유사도 순 후보일 뿐 적용 보증이 아니다. 무관하면 버리고, 실제 근거로 쓴 것만 appliedPrecedentIds 에 넣는다. 제공된 사건번호 외는 지어내지 못한다.
- 유해성이 인정되지 않는 후보는 반환하지 않는다 — 1차의 "넉넉히 포함"과 짝.
- 성립 요건 판단이 전부 여기 있다: - 협박: 구체적 해악의 고지가 있어야 한다. 압박·재촉·조롱·퇴장 금지만으로는 협박이 아니다. 말다툼 중 즉발적 분노 표시는 제외하되, 거부 의사를 밝힌 상대에 대한 일방적 해악 고지는 협박이다. - 명예훼손: 검증 가능한 구체적 사실의 적시 필요. 추상적 경멸은 모욕. - 공연성: legalContext 기준. 1:1이면 모욕·명예훼손 성립이 어렵고, 전파 가능성 예외는 판례가 있으면 그에 따른다. - 모욕과 언어폭력을 같은 메시지에 동시에 붙이지 않는다(중복 조문 방지).
- 갈취·강요: 요구와 해악 고지가 한 구간 안에서 결합돼 있으면 그 결합 자체를 평가한다 — 메시지 단위 때는 요건이 조각나서 놓치던 부분이다.
- 유형 8종: 언어폭력·명예훼손·모욕·성희롱·협박·스토킹·집단따돌림·갈취강요. 구조화 출력(zod 스키마 강제)이라 이 밖의 값은 물리적으로 나올 수 없다.

⑤⑥ 역치환·집계 — 코드

- AI가 쓴 reason 의 가명을 실명으로 되돌린다.
- 집계는 코드가 센다(LLM은 숫자를 틀린다). 건수·유형·정도는 구간 단위, 발신자·날짜는 구간에 속한 메시지 전부로 센다 (구간 하나에 발신자가 둘이면 둘 다 집계됨 — 동조자 포함). 기간, 반복성은 메시지 개수가 아니라 서로 다른 날짜 수로 판단한다 (같은 날 몇 시간 내 연속 전송은 한 덩어리 — 대법원 2023도5814 취지). 서로 다른 3일 이상이면 반복성 인정 범위.
- 발신자별 집계는 학폭법상 따돌림의 "가해자 2명 이상" 요건 판단 재료가 된다. 동조 발화("ㅋㅋ", "ㅇㅈ")가 잡히면 동조자도 별도로 집계된다.

⑦ 조문 매핑 — 코드 (law-registry.ts)

AI가 낸 harmTypes 를 조문으로 바꾼다. AI는 여기 관여하지 않는다.

협박 → 형법 제283조 — ① 3년 이하의 징역, 500만원 이하 벌금

· ② 5년 이하의 징역, 700만원 이하 벌금 [시행 2026.09.13]

반의사불벌죄 — 합의하면 처벌할 수 없습니다.

- 형량은 하드코딩이 아니라 data/law-articles.json 의 조문 원문에서 항 단위로 추출한다. 법이 개정되면 조문만 다시 받으면 자동 반영된다. (이 구조 덕에 개정으로 어긋난 형량 2건을 실제로 잡았다 — 정통망법 70조② 5천→7천만원, 저작권법 136조① 5년/5천→7년/1억)

- **1:1 대화 분기:** 공연성이 필요한 유형(모욕·명예훼손)은 `context === 'dm'` 이면 자동으로 정통망법 74조(반복 전송)로 전환된다. 성립 불가능한 죄명을 안내하면 고소 각하·역고소 위험이 있기 때문.
- 소추요건(친고죄 6개월·반의사불벌·합의 무관)도 유형별로 함께 붙는다.
- 조문 동기화: `law-api.service.ts` 가 국가법령정보 API로 주기 실행용. **런타임에는 절대 호출하지 않는다** (법은 몇 달 단위로 바뀌고, 외부 API 장애가 분석 실패로 전파되면 안 된다).

⑧ PDF — `report-pdf.service.ts`

Puppeteer(헤드리스 크롬)로 A4 렌더. 브라우저 인스턴스는 재사용하고 모듈 종료 시 정리.

- 항목 1개 = 구간 1개. 구간이 여러 발화면 발화마다 시각·발신자를 붙여 한 줄씩 인용한다.
- `legal: true` — 항목마다 관련 조항·형량·소추요건, 말미에 삭제·차단 절차 (정통망법 44조의2/44조의7), 학폭 절차, 민사 트랙(민법 750·751·755).
- `legal: false` — 조항 대신 AI의 판단 근거(`reason`)만.
- AI가 쓴 `reason` 과 판례 사건번호는 `legal: true` 문서에 **넣지 않는다** — 수사·상담 기관이 보는 자료에 AI 추론이 사실처럼 섞이면 안 되고, 판례 적용을 우리가 보증하는 모양이 되면 안 된다.
- 항목은 `break-inside: avoid` 로 페이지 경계에서 잘리지 않는다. 매 페이지 푸터에 "본 문서는 참고용이며 법률 자문이 아닙니다".

5. 검증 상태

구간 단위 전환(2026-09-08) 이후 **실AI 재측정은 아직 안 됐다** — API 키 무효 상태.
구간 로직 자체는 단위 테스트 4개(타깃 변환·집계·문서·패턴)와 PDF 스모크로 검증했고,
아래 실측치는 메시지 단위 시절의 값이다. 키가 복구되면 회귀 러너(예소/eval-runner.mjs,
구간 스키마로 이식됨)로 재측정한다 — 특히 서틀 시퀀스 5건이 구간 1개로 묶여 공갈 판례가
붙는지가 확인 포인트.

프로토타입 폴더(예소/)의 회귀 러너(`eval-runner.mjs`)로 성격이 다른 3개 대화를 자동 검사한다 — 프롬프트·풀·코드를 고치면 반드시 다시 돌릴 것:

케이스	결과
중증 학급 단톡 57건	확정 29건 · 즉시조치 9건 미탐 0 · 해악 고지 없는 4건에 협박 안 붙음
정상+쌍방장난 18건	후보 0건 (오탐 하한 — "브론즈 주제에ㅋㅋ" 등 전부 통과)
1:1 협박 12건	후보 8 → 확정 6 (2차 탈락 작동) · 금품 요구에 갈취강요

NestJS 이관 후 E2E: 분석 스트리밍(확정 10건)·PDF 410KB·DTO 검증(잘못된 context→400) 확인.

6. 실행·운영

```
npm install
npm run build
node dist/main.js          # http://localhost:3000
```

- `.env` 에 `AI_API_KEY=sk-ant-...` (`main.ts`가 `ANTHROPIC_API_KEY`로 옮겨 SDK에 전달). `.gitignore` 에 등록돼 있어 커밋되지 않는다 — 키를 코드나 커밋에 넣지 말 것.
- 법령 API용 `API_KEY` (`open.law.go.kr` OC 값)는 동기화 스크립트에만 필요.
- 분석 1회 = Claude API 2회 호출. 대화 크기에 따라 30초~2분, 토큰 1만~2만.
- 로그: 분석 시작/완료(건수·패턴·소요시간)·문서 생성(크기)이 `SafeguardController` 로거로 남는다.

7. 알려진 한계 / 남은 일

- 판례 매칭이 빈자리 — 팀원 벡터 DB 연결 필요(`NoopPrecedentProvider` 교체). 구간 전환으로 `targetText` 에 사실 요약이 앞서 붙어 문체 차이는 완화됐고, 계약에 유사도 점수 추가는 여전히 제안 상태.
- 대용량 청킹 없음 — 단일 패스라 수천 건 대화는 출력 한도를 넘을 수 있다. 세션(날짜) 단위 분할이 반복성 법리와도 맞는 방향.
- 리눅스 한글 폰트 — PDF 폰트가 macOS/Windows 기준이라 리눅스 배포 시 `fonts-noto-cjk` 설치 또는 폰트 임베드 필요.
- 역치환 시 조사 어긋남("민준가") — 사소하지만 `legal:false` 문서에 보일 수 있음.
- 유해 판정 기준의 근거(판례 조사)는 예소/`safeguard-law-reference.md`, 판단이 갈린 실측 기록은 예소/샘플-분석결과-AI.json 참고.