


Safe Guard — 대화 분석·문서 생성 작동 방식

담당 기능 #2(수집한 대화의 AI 분석) · #4(분석 결과의 문서 정리) / NestJS 백엔드
마지막 갱신 2026-08-13 · 본문의 모든 수치는 실제 실행에서 측정한 값이다.

1. 한눈에 보기

대화 내보내기 파일 하나가 정리 문서 PDF가 되기까지:



- AI 호출은 ②와 ④, 딱 두 번. 나머지는 전부 결정론적 코드다.
- 원칙: 의미 판단은 AI가, 숫자 집계·법조항은 코드가. AI에게 법조를 맡기면 없는 조항을 지어내고(할루시네이션), 개별 사안에 법을 적용해 판단해 주는 것은 법률사무여서 변호사법 문제가 생긴다. 조문·형량은 국가법령정보 API에서 수집한 원문만 쓴다.
- 이 분석은 참고용이며 법적 판단이 아니다. 문서 매 페이지에 면책이 박힌다.

실측 (57건 학급 단톡 샘플 기준):

구간	값
1차 선별	약 24초, 후보 30건
2차 판단	약 48초, 확정 29건 (탈락 1건)
토큰	입력 약 14,000 / 출력 약 5,000
정리 문서	A4 7페이지, 400~500KB

2. 코드 지도

src/safeguard/	
└ kakao-parser.ts	① 카톡 내보내기 파서 (3형식 자동 감지)
└ anonymizer.ts	① 가명화 - 실명·연락처는 기기 밖으로 안 나감
└ safeguard-analysis.service.ts	②④⑥ 1차·2차 프롬프트, 코드 패턴 검출, 집계
└ precedent-provider.ts	③ 판례 모듈 계약(입출력 바디) + 목업
└ law-registry.ts	⑦ 유형→조문 매핑, 형량 추출, DM 분기
└ law-api.service.ts	법령 API 동기화 (런타임 호출 안 함)
└ report-pdf.service.ts	⑧ Puppeteer PDF
└ safeguard.controller.ts	HTTP 계층 (분석 스트리밍 · PDF)
└ dto/analyze.dto.ts	요청 검증 (class-validator)
└ safeguard.module.ts	
data/law-articles.json	조문 16건 - 법령 API 원문 스냅샷
data/판례-풀.json	판례 14건 - 사건번호·판시사항 전부 판례 API 원문
public/safeguard-ui.html	모바일 UI

3. HTTP API

GET / — UI

모바일 전용 화면. 업로드 → 확인(대화방 종류·피해자 선택) → 분석 진행 → 결과·다운로드.

POST /api/analyze — 분석

```
// 요청
{ "rawText": "<내보내기 파일 원문>",
  "context": "dm | small_group | large_group | public",
  "victimName": "윤아" }
```

응답은 `application/x-ndjson` 스트림 — 파이프라인이 도는 동안 진행 이벤트가 한 줄씩 온다:

```
{ "type": "stage", "stage": "anonymize" }
{ "type": "stage", "stage": "screen" }
{ "type": "stage", "stage": "screen_done", "candidates": 30 }
{ "type": "stage", "stage": "match_done", "precedents": 13 }
{ "type": "stage", "stage": "judge" }
{ "type": "stage", "stage": "judge_done", "flagged": 29 }
{ "type": "result", "flagged": [ ... ], "patterns": [ "떼카", "카톡감옥", "서틀" ] }
// 실패 시: { "type": "error", "message": "..." }
```

flagged 항목 형태:

```
{ "no": 38, // 메시지 번호 - 원문은 클라이언트가 자기 파싱본에서 조회
  "harmTypes": ["협박"], // 8종 중 복수 가능
  "severity": "즉시조치", // 관찰 | 주의 | 즉시조치 (점수 아님)
  "reason": "...해약 고지", // 판단 근거 한 줄
  "appliedPrecedentIds": ["2006도546"] } // 실제 근거로 쓴 판례 (내부 추적용, 문서엔 안 나감)
```

POST /api/report — 정리 문서 PDF

```
// 요청 = analyze 요청 + 그 결과
{ "rawText": "...", "context": "...", "victimName": "...",
  "result": { "flagged": [...], "patterns": [...] },
  "legal": true } // true: 조항·절차 포함 / false: 판단 근거만
```

응답: application/pdf.

- `context` 는 enum으로 강제 검증한다(ValidationPipe). 이 값 하나로 적용 법조가 통째로 걸리기 때문(6절)에 잘못 들어오면 400으로 거절한다.
- `whitelist: true` 라서 검증 데코레이터가 없는 DTO 필드는 조용히 제거된다. 필드를 추가할 땐 반드시 데코레이터를 붙일 것 (실제로 `no` 필드가 스트립되어 PDF 생성이 터진 적이 있다).

4. 단계별 상세

① 파싱 — `kakao-parser.ts`

카카오톡 내보내기 두 형식을 자동 감지한다:

PC형:	[민준] [오후 2:20] 본문	← 날짜는 구분선에서 상태로 유지
모바일형:	2026. 6. 23. 오후 10:59, 이름 : 본문	← 매 줄에 날짜
	2026. 6. 23. 오후 10:59: A님이 B님과 C님을 초대했습니다.	← 시스템 줄은 침표가 아니라 콜론
	메시지가 삭제되었습니다.	← 시각 없는 단독 줄

처리하는 것: 오전·오후→24시간(오후 12시는 12시, 오전 12시는 00시), 여러 줄 메시지 병합, 시스템 이벤트(나감·초대·강퇴·삭제) 추출, 다중 초대의 대상 분해 ("A님, B님과 C님을 초대" → `targets: [A,B,C]`).

시스템 이벤트가 중요한 이유: 카톡감옥·방폭은 텍스트에 욕설이 0건이라 입·퇴장 로그가 유일한 증거다.

① 가명화 — `anonymizer.ts`

외부(AI API·판례 검색)로 나가기 전에 신원을 지운다:

민준→학생A · 윤아→학생E ... "야 김윤아" → "야 학생E" (성이 붙은 형태까지 흡수)
전화번호 → [전화번호] · 주민번호 → [주민번호] · URL → [링크]

- 가명↔실명 매핑은 서버 메모리에만 존재한다. AI가 돌려준 `reason` 은 역치환한다.
- 메시지 번호(`no`) 는 순서 기반이라 가명화와 무관하게 앵커로 동작한다.
- 한계: 참여자 목록에 없는 제3자 실명은 잡지 못한다. 완전한 익명화가 아니라 최선 노력(best-effort) 마스킹이다.

같은 시점에 코드 패턴 검출이 돈다 — AI 없이 결정론적으로:

카톡감옥: 피해자 퇴장 → 재초대 2회 이상
방폭: 피해자 초대·입장 후 10분 내 타인 2명 이상 퇴장

의미 판단이 필요한 나머지 패턴(떼카·서틀·은따·저격글·반톡배제)은 1차 AI가 관찰하고, 최종 `patterns` 는 둘의 합집합이다. AI가 놓쳐도 코드가 잡는 안전망.

② 1차 선별 — AI, effort low

번호 매긴 **대화 전문**을 주고 "유해 후보를 고르기만 해라"를 시킨다. 1차는 전체 대화를 읽는 유일한 AI 단계다.

- **애매하면 포함** — 여기서 빠진 메시지는 이후 단계에 전달되지 않는다(미탐은 복구 불가). 잘못 들어간 것은 2차가 거른다.
- 확실히 무해한 것만 제외: 일상 대화, 피해자 발화, 무례·불쾌 수준, 지목 없는 감탄사형 욕설("ㅅㅂ 시험 망함"), 일상 초성체(ㅇㅋ, ㄱㅅ, ㄴㅇㄹ...), 쌍방 장난.
- 동조성 반응은 포함: 비하 직후의 "ㅋㅋㅋㅋ"."ㅇㅈ"."ㄱㄱ"는 집단따돌림의 구성 발화다(가해자만 웃고 대상자는 웃지 않으면 조롱).
- 후보마다 두 가지를 붙인다: - **victimIdentifiable** — 특정성. 이름·2인칭·멘션뿐 아니라 "어떤 애가" 식 맥락 지목 포함 - **contextNote** — 2차가 전체 대화를 못 보므로 앞뒤 상황 한 줄. **죄명·유형 단어 금지, 관찰된 사실만** (1차의 판정이 노트에 섞이면 2차가 그것에 끌려가는 앵커링이 실측에서 확인되어 금지 규칙을 넣었다)

③ 판례 매칭 — 팀원 모듈 (현재 묵업)

계약(입출력 바디)은 **precedent-provider.ts**에 타입으로 고정돼 있다:

```
입력: analysisTargets[] = { targetMessageId, targetText,
                           legalContext: { isGroupChat, audienceCount, victimIdentifiable } }
출력: precedentDict      = { 사건번호: 요지 한 줄 }           ← 중복 제거된 사전
      analysisTargets[] + matchedPrecedentIds[3]             ← 메시지에 번호만
```

- **isGroupChat** · **audienceCount**는 코드가(방 정보), **victimIdentifiable**은 1차 AI가 채운다.
- 실제 구현은 팀원의 벡터 DB — **targetText**와 가장 가까운 판례 문구 3개를 자연어 검색으로 리턴. 준비 전까지 **MockPrecedentProvider** (문자 바이그램 코사인)가 같은 계약으로 동작한다. **교체 지점은 safeguard-analysis.service.ts의 precedents 필드** 하나.
- top-3는 임계값이 없어서 무관한 판례도 반드시 3개가 붙는다 — 그래서 2차 프롬프트에 "무관하면 버려라"가 있다.

데이터: **data/판례-풀.json** 14건. **사건번호·요지 전부 판례 API 원문**이다 (지어낸 요지가 DB에 들어가면 2차 판단 전체가 오염된다). 집단따돌림은 판례 DB에 실제 판사가 없어 학폭법 2조 정의 조문이 판단 근거임을 풀에 명시했다.

④ 2차 판단 — AI, effort medium

대화 전문 없이 **판례 사전 + 후보 목록**을 받는다. 후보마다:

```
[0035] 피해자 식별: 예 · 판례 후보: 2003도709, ...
[0033] 학생E: 나 돈 없는데           ← 원문 윈도우 ±2
[0034] 학생A: 없으면 만들어와야지   (해석되지 않은 원문 - 앵커링 방지)
▶ [0035] 학생A: 안사오면 어떻게 되는지 알지
[0036] 학생E: 알겠어
맥락: 돈이 없다는 거절 직후 ...      ← 1차 노트 (참고용)
```

핵심 규칙:

- 판례는 유사도 순 후보일 뿐 적용 보증이 아니다. 무관하면 버리고, 실제 근거로 쓴 것만 **appliedPrecedentIds**에 넣는다. 제공된 사건번호 외는 지어내지 못한다.
- 유해성이 인정되지 않는 후보는 반환하지 않는다 — 1차의 "넉넉히 포함"과 짝.
- 성립 요건 판단이 전부 여기 있다: - 협박: **구체적 해악의 고지**가 있어야 한다. 압박·재촉·조롱·퇴장 금지만으로는 협박이 아니다. 말다툼 중 즉발적 분노 표시는 제외하되, 거부 의사를 밝힌 상대에 대한 일방적 해악 고지는 협박이다. - 명예훼손: 검증 가능한 구체적 사실의 적시 필요. 추상적 경멸은 모욕. - 공연성: **legalContext** 기준. 1:1이면 모욕·명예훼손 성립이 어렵고, 전파 가능성 예외는 판례가 있으면 그에 따른다. - 모욕과 언어폭력을 같은 메시지에 붙이지 않는다(중복 조문 방지).

- 유형 8종: 언어폭력·명예훼손·모욕·성희롱·협박·스토킹·집단따돌림·갈취강요. 구조화 출력(zod 스키마 강제)이라 이 밖의 값은 물리적으로 나올 수 없다.

⑤⑥ 역치환·집계 — 코드

- AI가 쓴 `reason` 의 가명을 실명으로 되돌린다.
- 집계는 코드가 센다(LLM은 숫자를 틀린다): 유형별·발신자별 건수, 기간, **반복성은 메시지 개수가 아니라 서로 다른 날짜 수로** 판단한다 (같은 날 몇 시간 내 연속 전송은 한 덩어리 — 대법원 2023도5814 취지). 서로 다른 3일 이상이면 반복성 인정 범위.
- 발신자별 집계는 학폭법상 따돌림의 "가해자 2명 이상" 요건 판단 재료가 된다. 동조 발화("ㅋㅋ", "ㅇㅈ")가 잡히면 동조자도 별도로 집계된다.

⑦ 조문 매핑 — 코드 (`law-registry.ts`)

AI가 낸 `harmTypes` 를 조문으로 바꾼다. AI는 여기 관여하지 않는다.

협박 → 형법 제283조 — ① 3년 이하의 징역, 500만원 이하 벌금
 · ② 5년 이하의 징역, 700만원 이하 벌금 [시행 2026.09.13]
 반의사불벌죄 — 합의하면 처벌할 수 없습니다.

- 형량은 하드코딩이 아니라 `data/law-articles.json` 의 **조문 원문에서 항 단위로 추출**한다. 법이 개정되면 조문만 다시 받으면 자동 반영된다. (이 구조 덕에 개정으로 어긋난 형량 2건을 실제로 잡았다 — 정통망법 70조② 5천→7천만원, 저작권법 136조① 5년/5천→7년/1억)
- **1:1 대화 분기**: 공연성이 필요한 유형(모욕·명예훼손)은 `context === 'dm'` 이면 자동으로 정통망법 74조(반복 전송)로 전환된다. 성립 불가능한 죄명을 안내하면 고소 각하·역고소 위험이 있기 때문.
- 소추요건(친고죄 6개월·반의사불벌·합의 무관)도 유형별로 함께 붙는다.
- 조문 동기화: `law-api.service.ts` 가 국가법령정보 API로 주기 실행용. **런타임에는 절대 호출하지 않는다** (법은 몇 달 단위로 바뀌고, 외부 API 장애가 분석 실패로 전파되면 안 된다).

⑧ PDF — `report-pdf.service.ts`

Puppeteer(헤드리스 크롬)로 A4 렌더. 브라우저 인스턴스는 재사용하고 모듈 종료 시 정리.

- `legal: true` — 항목마다 관련 조항·형량·소추요건, 말미에 삭제·차단 절차 (정통망법 44조의2/44조의7), 학폭 절차, 민사 트랙(민법 750·751·755).
- `legal: false` — 조항 대신 AI의 판단 근거(`reason`)만.
- AI가 쓴 `reason` 과 판례 사건번호는 `legal: true` 문서에 **넣지 않는다** — 수사·상담 기관이 보는 자료에 AI 추론이 사실처럼 섞이면 안 되고, 판례 적용을 우리가 보증하는 모양이 되면 안 된다.
- 항목은 `break-inside: avoid` 로 페이지 경계에서 잘리지 않는다. 매 페이지 푸터에 "본 문서는 참고용이며 법률 자문이 아닙니다".

5. 검증 상태

프로토타입 폴더(예소)의 회귀 러너(`eval-runner.mjs`)로 성격이 다른 3개 대화를 자동 검사한다 — 프롬프트·풀·코드를 고치면 반드시 다시 돌릴 것:

케이스	결과
중증 학급 단톡 57건	확정 29건 · 즉시조치 9건 미탐 0 · 해악 고지 없는 4건에 협박 안 붙음
정상+쌍방장난 18건	후보 0건 (오탐 하한 — "브론즈 주제에ㅋㅋ" 등 전부 통과)
1:1 협박 12건	후보 8 → 확정 6 (2차 탈락 작동) · 금품 요구에 갈취강요

NestJS 이관 후 E2E: 분석 스트리밍(확정 10건)·PDF 410KB·DTO 검증(잘못된 context→400) 확인.

6. 실행·운영

```
npm install
npm run build
node dist/main.js          # http://localhost:3000
```

- `.env` 에 `AI_API_KEY=sk-ant-...` (main.ts가 `ANTHROPIC_API_KEY`로 옮겨 SDK에 전달). `.gitignore` 에 등록돼 있어 커밋되지 않는다 — 키를 코드나 커밋에 넣지 말 것.
- 법령 API용 `API_KEY` (open.law.go.kr OC 값)는 동기화 스크립트에만 필요.
- 분석 1회 = Claude API 2회 호출. 대화 크기에 따라 30초~2분, 토큰 1만~2만.
- 로그: 분석 시작/완료(건수·패턴·소요시간)·문서 생성(크기)이 `SafeguardController` 로거로 남는다.

7. 알려진 한계 / 남은 일

- 판례 매칭이 목업 — 팀원 벡터 DB로 교체 필요. 구어 원문 ↔ 판시사항 문어체의 스타일 차이 때문에 매칭 품질 검증이 필요하고, 계약에 유사도 점수 추가를 제안한 상태.
- 대용량 청킹 없음 — 단일 패스라 수천 건 대화는 출력 한도를 넘을 수 있다. 세션(날짜) 단위 분할이 반복성 법리와도 맞는 방향.
- 리눅스 한글 폰트 — PDF 폰트가 macOS/Windows 기준이라 리눅스 배포 시 `fonts-noto-cjk` 설치 또는 폰트 임베드 필요.
- 역치한 시 조사 어긋남("민준가") — 사소하지만 `legal:false` 문서에 보일 수 있음.
- 유해 판정 기준의 근거(판례 조사)는 예소/safeguard-law-reference.md, 판단이 갈린 실측 기록은 예소/샘플-분석결과-AI.json 참고.